



Matematikai statisztika

Soós Anna

Babes-Bolyai Tudományegyetem,
Matematika és Informatika Kar
anna.soos@ubbcluj.ro



2

(2 of 27)



Bevezetés a statisztikába

- adatok tudományos gyűjtése és vizsgálata a XVII-XVIII. század Németországában kezdődött
- **statisztika** elnevezés: Martin Schmeitzel "Collegium polotico-statisticum" munkájában
- **matematikai statisztika:** Bayes, Laplace, Gauss, Csebisev, Markov, F. Galton, K. Pearson, R.A. Fisher, J. Neyman, A.N. Kolmogorov, A.M. Leapunov, M.Szmirnov, Wald Ábrahám, C.R. Rao





3

(3 of 27)



A valószínűségszámítás elméletében:
 $(\Omega, \mathcal{K}, \mathbb{P})$, $\mathbb{P}$ valószínűség adott

A gyakorlati problémákban a valószínűség nem ismert,
legfeljebb előfeltételezéseink vannak róla.

A statisztika feladata: a véletlen kísérletek vagy a véletlen
tömegjelenségekre vonatkozó megfigyelések
segítségével következtetni egy valószínűségre vagy
annak egy jellemzőjére,





4

(4 of 27)



Statisztikai sokaság, statisztikai minták

A statisztika a sokszor ismétlődő vagy ismételhető jelenségek, események számadatainak
-összegyűjtésével,
-rendezésével és
-elemzésével foglalkozik.

A megfigyelt értékek összesége **statisztikai minta**



5

(5 of 27)



A statisztika :

- leíró vagy deduktív statisztika
- induktív statisztikanak vagy statisztikai következtetéselmélet vagy matematikai statisztika

A matematikai statisztika:

- mintavételi elmélet
- becsléselmélet
- hipotézisellenőrzés



6

(6 of 27)



A **statisztikai sokaság**: S halmaz, amelyet az X tulajdonság, jellemző, szempontjából vizsgálunk.

Értelmezés

Az $(S, \mathcal{S}, \mathcal{P})$ statisztikai mező az $(S, \mathcal{S})$ eseménytérből és a rajta definiálható $\mathcal{P}$ valószínűségek családjából áll.



7

(7 of 27)



Értelmezés

Az $(S, \mathcal{S}, \mathcal{P})$ statisztikai mezőn értelmezett $\mathbb{F}_X$ eloszlású X valószínűségi változóra vonatkozó **minta**

$X_1, X_2, \dots, X_n$, amelyek:

- függetlenek

- azonos, $\mathbb{F}_X$ eloszlásúak.

n -et a minta nagyságának és az

$X_1, X_2, \dots, X_n$ valós számok aminta egy realizációja.

Az eloszlást az igazi $\mathbb{P} \in \mathcal{P}$ valószínűség szerint értettük:

$$\mathbb{F}_X(x) = \mathbb{P}(X < x) = \mathbb{P}(X_i < x).$$





8

(8 of 27)



A statisztikai sokaságból vett minta választása történhet:

- ▶ véletlenszerűen:
 - ▶ azonos vagy különböző valószínűséggel jelenhetnek meg az egyedek a mintában
 - ▶ visszatevéssel vagy visszatevés nélkül
- ▶ nem véletlenszerűen:
 - ▶ rendezetten, adott szabály szerint
 - ▶ tipikusan, amikor előzetes ismeretek alapján a sokaságra jellemző egyedeket választunk
 - ▶ osztályokra bontjuk a statisztikai sokaságot és az egyes osztályok jellemző egyedeit választjuk





Mintavételi elmélet

A mintavételi elmélet a statisztikai sokaság és belőle vett minta közti kapcsolatot vizsgálja.

S statisztikai sokaság, $X_1, X_2, \dots, X_n$ egy belőle vett n elemű minta, melyet az X jellemző szerint

$$Z_n = h_n(X_1, X_2, \dots, X_n),$$

valószínűségi változó egy statisztika,

$$h_n : \mathbb{R}^n \rightarrow \mathbb{R}^k$$

mérhető függvény

$z_n = h_n(x_1, x_2, \dots, x_n)$ a statisztika értéke.



Mintabeli vagy tapasztalati várható érték

A mintabeli vagy tapasztalati várható érték

$$\bar{X} = \frac{1}{n} \sum_{k=1}^n x_k,$$

az elméleti várható érték jó közelítését adja.





Tétel

Ha az X jellemző várható érték $m = \mathbb{E}(X)$ és szórás $\sigma^2 = \mathbb{D}^2(X)$, akkor

$$\mathbb{E}(\bar{X}) = m \qquad \mathbb{D}^2(\bar{X}) = \frac{1}{n}\sigma^2.$$

Bizonyítás Felhasználva a várható érték és szórás tulajdonságait és azt, hogy visszatevéssel választunk

$$\mathbb{E}(\bar{X}) = \frac{1}{n} \sum_{k=1}^n \mathbb{E}(X_k) = \frac{1}{n} \sum_{k=1}^n \mathbb{E}(X) = \frac{1}{n} n m = m,$$

illetve

$$\mathbb{D}^2(\bar{X}) = \frac{1}{n^2} \sum_{k=1}^n \mathbb{D}^2(X_k) = \frac{1}{n^2} \sum_{k=1}^n \mathbb{D}^2(X) = \frac{1}{n^2} n \sigma^2 = \frac{1}{n} \sigma^2.$$



Feladat:

Igazolja, hogy, ha X normális eloszlású valószínűségi változó $N(m, \sigma)$ paraméterekkel, akkor $\bar{X}$ is normális eloszlású, melyek a paraméterei?



Tétel

Ha X várható értéke, $m = \mathbb{E}(X)$ és szórása $\sigma^2 = \mathbb{D}^2$ akkor a Z_n statisztika

$$Z_n = \frac{\bar{X} - m}{\frac{\sigma}{\sqrt{n}}}$$

Bernoulli értelemben (eloszlásban) az $N(0, 1)$ -hoz konvergál, ha $n \rightarrow \infty$.

Bizonyítás A Lindenberg tétel alapján

$$X_{(n)} = \sum_{k=1}^n \frac{X_k - m}{\sigma \sqrt{n}} \text{ eloszlásban tart } N(0, 1)\text{-hoz.}$$

Igazolnunk kell, hogy $X_{(n)} = Z_n$.

$$X_{(n)} = \frac{1}{\sigma \sqrt{n}} \left(\sum_{k=1}^n X_k - m n \right) = \frac{1}{\sigma \sqrt{n}} (n \bar{X} - m n) = \frac{\bar{X} - m}{\frac{\sigma}{\sqrt{n}}} = Z_n.$$



A mintabeli k.adrendű momentum

$$\bar{\nu}_k = \frac{1}{n} \sum_{i=1}^n X_i^k,$$

Tétel

Ha az X létezik $\nu_{2k} = \mathbb{E}(X^{2k})$, akkor

$$\mathbb{E}(\bar{\nu}_k) = \nu_k \quad \text{és} \quad \mathbb{D}^2(\bar{\nu}_k) = \frac{1}{n} (\nu_{2k} - \nu_k^2).$$

Ha $n \rightarrow \infty$, akkor

$$\frac{\bar{\nu}_k - \nu_k}{\frac{\sqrt{\nu_{2k} - \nu_k^2}}{\sqrt{n}}}$$

eloszlásban az $N(0, 1)$ normáleloszáshoz tart.



A mintabeli k.adrendű centrált moment

$$\bar{\mu}_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k,$$

Tétel

Ha az X -re létezik ν_4 , akkor

$$\mathbb{E}(\bar{\mu}_2) = \frac{n-1}{n} \sigma^2, \quad \mathbb{D}^2(\bar{\mu}_2) = \frac{n-1}{n^3} \left[(n-1) \mu_4 - (n-3) \sigma^4 \right],$$

és

$$C(\bar{X}, \bar{\mu}_2) = \frac{n-1}{n^2} \mu_3,$$

ahol $\sigma^2 = \mathbb{D}^2(X)$.



Bizonyítás Az első összefüggés igazolásához felírhatjuk

$$\begin{aligned}
 \mathbb{E}(\bar{\mu}_2) &= \mathbb{E}(\bar{\nu}_2) - \mathbb{E}(\bar{\nu}_1^2) = \nu_2 - \frac{1}{n^2} \mathbb{E} \left(\sum_{k=1}^n X_k^2 + 2 \sum_{i,j=1, i<j}^n X_i X_j \right) \\
 &= \nu_2 - \frac{1}{n^2} \left(\sum_{k=1}^n \mathbb{E}(X_k^2) + 2 \sum_{i,j=1, i<j}^n \mathbb{E}(X_i) \mathbb{E}(X_j) \right) = \\
 &= \nu_2 - \frac{1}{n^2} \left(n\nu_2 + n(n-1)\nu_1^2 \right) = \nu_2 - \frac{1}{n}\nu_2 - \frac{n-1}{n}\nu_1^2 = \\
 &= \frac{n-1}{n} (\nu_2 - \nu_1^2) = \frac{n-1}{n} \sigma^2.
 \end{aligned}$$





Az előbbi tulajdonság alapján

$$\mathbb{D}^2(\bar{\mu}_2) = \frac{1}{n} (\mu_4 - \mu_2^2) + O\left(\frac{1}{n^2}\right),$$

tehát

$$\mathbb{D}^2(\bar{\mu}_2) \simeq \frac{1}{n} (\mu_4 - \mu_2^2).$$

$$C(\bar{X}, \bar{\mu}_2) = \frac{n-1}{n^2} \mu_3 \Rightarrow \bar{X} \text{ és } \bar{\mu}_2 \text{ korrelálatlanok ha}$$

$n \rightarrow \infty$,

ha az X -re $\mu_3 = 0 \Rightarrow \bar{X}$ és $\bar{\mu}_2$ korreláltak.





Mintabeli vagy tapasztalati vagy korrigált szórás

$$\bar{\sigma}^2 = \frac{1}{n-1} \sum_{k=1}^n (X_k - \bar{X})^2$$

$$\Rightarrow \bar{\sigma}^2 = \frac{n}{n-1} \bar{\mu}_2$$

$$\mathbb{D}^2(\bar{\sigma}^2) = \frac{1}{n(n-1)} \left[(n-1) \mu_4 - (n-3) \mu_2^2 \right],$$

$$\mathbb{C}(\bar{X}, \bar{\sigma}^2) = \frac{1}{n} \mu_3.$$



Az előbbi tulajdonság alapján

$$\mathbb{D}^2(\bar{\mu}_2) = \frac{1}{n} (\mu_4 - \mu_2^2) + O\left(\frac{1}{n^2}\right),$$

tehát

$$\mathbb{D}^2(\bar{\mu}_2) \simeq \frac{1}{n} (\mu_4 - \mu_2^2).$$

$$C(\bar{X}, \bar{\mu}_2) = \frac{n-1}{n^2} \mu_3 \Rightarrow \bar{X} \text{ és } \bar{\mu}_2 \text{ korrelálatlanok ha}$$

$n \rightarrow \infty$,

ha az X -re $\mu_3 = 0 \Rightarrow \bar{X}$ és $\bar{\mu}_2$ korreláltak.





Hasonlóan igazolható, hogy

$$\frac{\bar{\mu}_2 - \mu_2}{\frac{\sqrt{\mu_4 - \mu_2^2}}{\sqrt{n}}}$$

eloszlásban az $N(0, 1)$ normáeloszláshoz tart, ha $n \rightarrow \infty$.



Mintabeli vagy tapasztalati vagy korrigált szórás

$$\bar{\sigma}^2 = \frac{1}{n-1} \sum_{k=1}^n (X_k - \bar{X})^2$$

$$\Rightarrow \bar{\sigma}^2 = \frac{n}{n-1} \bar{\mu}_2$$

$$\mathbb{D}^2(\bar{\sigma}^2) = \frac{1}{n(n-1)} \left[(n-1) \mu_4 - (n-3) \mu_2^2 \right],$$

$$\mathbb{C}(\bar{X}, \bar{\sigma}^2) = \frac{1}{n} \mu_3.$$



Tétel

Ha az X valószínűségi változóra létezik a k -adrendű elméleti centrált momentim $\mu_k = \mathbb{E} \left[\left(X - \mathbb{E}(X) \right)^k \right]$, akkor

$$\mathbb{E}(\bar{\mu}_k) = \mu_k + O\left(\frac{1}{n}\right).$$



A következő tételeket a becsléelméletben és a hipotézisellenőrzésben alkalmazzuk.

Tétel

Az S statisztikai sokaságból az X normáleloszlású $N(0, 1)$ jellemző szerint válasszuk az $X_1, X_2, \dots, X_n$ mintát. Ekkor az

$$U_n = \frac{\bar{X} - m}{\frac{\sigma}{\sqrt{n}}},$$
$$V_n = \frac{1}{\sigma^2} \sum_{k=1}^n (x_k - \bar{X})^2,$$

statisztikák független valószínűségi változók, U_n $N(0, 1)$ normáleloszlású, V_n pedig $n - 1$ szabadságfokú χ^2 eloszlású.



Tétel

Az S statisztikai sokaságból az X normáloszlású $N(m, \sigma)$ jellemző szerint válasszuk az $X_1, X_2, \dots, X_n$ mintát. Ekkor a

$$T = \frac{\bar{X} - m}{\frac{\sigma}{\sqrt{n}}} = \frac{\bar{X} - m}{\sqrt{\frac{\bar{\mu}_2}{n-1}}},$$

statisztika Student eloszlású $n - 1$ szabadságfokkal.



A következő tételeket a becsléelméletben és a hipotézisellenőrzésben alkalmazzuk.

Tétel

Az S statisztikai sokaságból az X normáleloszlású $N(0, 1)$ jellemző szerint válasszuk az $X_1, X_2, \dots, X_n$ mintát. Ekkor az

$$U_n = \frac{\bar{X} - m}{\frac{\sigma}{\sqrt{n}}},$$
$$V_n = \frac{1}{\sigma^2} \sum_{k=1}^n (x_k - \bar{X})^2,$$

statisztikák független valószínűségi változók, U_n $N(0, 1)$ normáleloszlású, V_n pedig $n - 1$ szabadságfokú χ^2 eloszlású.



Bizonyítás Az előbbi tétel jelöléseivel

$$T = \frac{U_n}{\sqrt{\frac{V_n}{n-1}}} \cdot \cdot$$

Valóban

$$\begin{aligned} \frac{U_n}{\sqrt{\frac{V_n}{n-1}}} &= \frac{\bar{X} - m}{\frac{\sigma}{\sqrt{n}}} \cdot \frac{\sqrt{n-1}}{\frac{1}{\sigma} \sqrt{\sum_{k=1}^n (x_k - \bar{X})^2}} = \frac{\bar{X} - m}{\frac{\sqrt{\frac{1}{n-1} \sum_{k=1}^n (x_k - \bar{X})^2}}{\sqrt{n}}} = \\ &= \frac{\bar{X} - m}{\frac{\bar{\sigma}}{\sqrt{n}}} = T. \end{aligned}$$





Az elméleti és tapasztalati eloszlásfüggvények kapcsolata

A mintavételi (empirikus) eloszlásfüggvény, az

$$\bar{F}_n(x) = \frac{\text{card}\{X_i \mid X_i < x, i = \overline{1, n}\}}{n}, \quad x \in \mathbb{R},$$

Tétel

Minden rögzített valós x esetén érvényes a

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\bar{F}_n(x) - F(x)| > \epsilon) = 0,$$

illetve $\bar{F}_n(x)$ aszimptotikusan normális

$$\sqrt{n} \frac{\bar{F}_n(x) - F(x)}{F_X(x)(1 - F_X(x))} \xrightarrow{\mathcal{B}} N(0, 1) \dots$$



Bizonyítás A Csebisev egyenlőtlenség miatt

$$0 \leq \mathbb{P}(|F_n(x) - F_X(x)| > \epsilon) \leq \frac{\mathbb{D}^2 F_n(x)}{\epsilon^2} = \frac{F_X(x)(1 - F_X(x))}{n\epsilon^2}$$

Az aszimptotikus normalitás a centrális határeloszlás következménye, mivel F_n független valószínűségi változók összege. ■.



Glivenko

Tétel

Legyen $\mathbb{F}$ az X j elméleti eloszlásfüggvény és tekintsünk az X jellemzőre egy n elemű visszatevéses mintavételt. Legyen $X_1, X_2, \dots, X_n$ valószínűségi változó és $\bar{\mathbb{F}}_n$ az eloszlásfüggvénye. Ekkor az mintabeli eloszlásfüggvény 1 valószínűséggel az elméleti eloszlásfüggvényhez konvergál:

$$\mathbb{P} \left(\left(\lim_{n \rightarrow \infty} \sup_{x \in \mathbb{R}} |\bar{\mathbb{F}}_n(x) - \mathbb{F}(x)| = 0 \right) \right) = 1.$$





Kolmogorov

Tétel

Legyen az X eloszlásfüggvény $\mathbb{F}$ folytonos és legyen n -elemű $X_1, X_2, \dots, X_n$ mintavétel az X jellemzőre. Ha $\bar{\mathbb{F}}_n$ mintaváteli eloszlásfüggvény, akkor

$$\lim_{n \rightarrow \infty} \mathbb{P}(\sqrt{n}d_n < x) = K(x), \quad x > 0,$$

ahol

$$d_n = \sup_{x \in \mathbb{R}} |\bar{\mathbb{F}}_n(x) - \mathbb{F}(x)|,$$

és

$$K(x) = \sum_{k=-\infty}^{+\infty} (-1)^k e^{-2k^2 x^2}, \quad x > 0,$$

a Kolmogorov függvény.



A statisztikai becslés elmélete

S statisztikai sokaságot az X jellemző szerint vizsgáljuk
 $\mathbb{F}(x; \theta)$ az eloszlásfüggvénye, ahol $\theta \in \mathbb{R}$
 $X_1, \dots, X_n$ a minta és $x_1, \dots, x_n$, $n \in \mathbb{N}$ egy realizációja.

Értelmezés

*Az X valószínűségi változó **valószínűségfüggvénye** az $f(x; \theta)$, mely az X valószínűségi változó sűrűségfüggvényét jelenti, ha X folytonos és a relatív gyakoriságot abban az esetben, ha X diszkrét valószínűségi változó.*



Értelmezés

Az $(X_1, X_2, \dots, X_n)$, valószínűségi vektor valószínűségfüggvényét, vagyis az

$$l(x_1, x_2, \dots, x_n; \theta) = \prod_{k=1}^n f(x_k; \theta).$$

függvényt az X jellemző **likelihood-függvényének** nevezzük.



$(X_1, X_2, \dots, X_n)$ minta
diszkrét esetben

$$\begin{aligned} l(x_1, x_2, \dots, x_n, \theta) &= \mathbb{P}_\theta(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) = \\ &= \prod_{k=1}^n \mathbb{P}_\theta(X_k = x_k), \end{aligned}$$

folytonos esetben

$$l(x_1, \dots, x_n, \theta) = \prod_{k=1}^n f(x_k, \theta),$$

tekintettel a függetlenségre.



A becsléselméletben a feladat egy olyan $T = T(X_1, X_2, \dots, X_n)$ statisztika meghatározása, amely elég jól becsüli a paraméterhalmazt.

Két módszer: pontbecslés és intervallumbecslés

Értelmezés

*Ha a θ paraméter értékét a $T = T(X_1, X_2, \dots, X_n)$ statisztika alapján közelítjük meg **pontbecslést** végzünk.*

Értelmezés

*Ha meghatározunk egy olyan véletlen intervallumot, amely bizonyos valószínűséggel közelíti meg a paraméter értékét **intervallumbecslésnek**, az intervallumot **konfidenciaintervallumnak** nevezzük.*



Elégséges becslés

Értelmezés

A $T(X_1, \dots, X_n)$ statisztika elégséges a $\mathcal{P}_\theta, \theta \in \mathbb{R}^k$ eloszlácsoládra nézve, ha

a.) diszkrét esetben az

$$\begin{aligned} f(x_1, x_2, \dots, x_n | T(x_1, x_2, \dots, x_n)) &= \\ = \mathbb{P}_\theta(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n | T(X_1, \dots, X_n) = T(x_1, \dots, x_n)) \end{aligned}$$

feltételes eloszlás független θ -tól.

b.) folytonos esetben a

$$f(x_1, x_2, \dots, x_{n-k} | s_1, s_2, \dots, s_k) \quad \square$$

feltételes sűrűségfüggvény független θ -tól.



Példa

X Poisson eloszlású $\lambda > 0$ $f(x; \lambda) = \frac{\lambda^x}{x!} e^{-\lambda}$, $x = 0, 1, 2, \dots$

$T = \sum_{k=1}^n X_k \Rightarrow T$ is Poisson eloszlású:

$$\mathbb{P}(T = s) = \frac{(n\lambda)^s}{s!} e^{-n\lambda}, \quad s = 0, 1, 2, \dots$$

$$f(x_1, x_2, \dots, x_n; \lambda | s) = P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n | T = s) =$$

$$= \frac{\mathbb{P}(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n, T = s)}{\mathbb{P}(T = s)} =$$

$$= \frac{\mathbb{P}(X_1 = x_1, \dots, X_{n-1} = x_{n-1}, X_n = s - \sum_{k=1}^{n-1} x_k)}{P(T = s)} =$$

$$= \frac{\mathbb{P}(X_n = s - \sum_{k=1}^{n-1} x_k) \prod_{i=1}^{n-1} \mathbb{P}(X_i = x_i)}{\mathbb{P}(T = s)} =$$

$$= \frac{\frac{\lambda^{s - \sum_{k=1}^{n-1} x_k}}{(s - \sum_{k=1}^{n-1} x_k)!} e^{-\lambda} \prod_{i=1}^{n-1} \left(\frac{\lambda^{x_i}}{x_i!} e^{-\lambda} \right)}{\frac{(n\lambda)^s}{s!} e^{-n\lambda}} = \frac{s!}{n^s x_1! x_2! \dots x_n!}.$$





Neyman-Fisher faktORIZÁCIÓS TÉTEL

Tétel

A $T(X_1, \dots, X_n)$ statisztika akkor és csak akkor elégséges a $\mathbb{P}_\theta, \theta \in \mathbb{R}^k$ eloszláscsaládra nézve, ha létezik a $h: \mathbb{R}^n \rightarrow \mathbb{R}$ mérhető függvény és a $g_\theta: \mathbb{R} \rightarrow \mathbb{R}$ nemnegatív függvény, amelyre:

a.) diszkrét esetben az együttes eloszlás

$$l(x_1, x_2, \dots, x_n, \theta) = g_\theta(T(x_1, x_2, \dots, x_n))h(x_1, x_2, \dots, x_n) \quad (1)$$

b.) folytonos esetben az együttes sűrűségfüggvény

$$l(x_1, x_2, \dots, x_n, \theta) = g_\theta(T(x_1, x_2, \dots, x_n))h(x_1, x_2, \dots, x_n)$$

azaz a θ -tól függő szorzótényező csak a T statisztikán keresztül függ a mintától.



Példa

Exponenciális az X jellemző, ha valószínűségfüggvénye

$$f(x; \theta) = \exp\{a(x)\alpha(\theta) + b(x) + \beta(\theta)\}.$$

Legyen

$$T = T(X_1, X_2, \dots, X_n) = \sum_{k=1}^n a(X_k)$$

$$l(x_1, x_2, \dots, x_n; \theta) = \prod_{k=1}^n f(x_k; \theta) =$$

$$= \exp\left\{\alpha(\theta) \sum_{k=1}^n a(x_k) + n\beta(\theta) + \sum_{k=1}^n b(x_k)\right\} =$$

$$= \exp\left\{\alpha(\theta) \sum_{k=1}^n a(x_k) + n\beta(\theta)\right\} \exp\left\{\sum_{k=1}^n b(x_k)\right\}.$$





Legyen

$$h(x_1, x_2, \dots, x_n) = \exp\left\{\sum_{k=1}^n b(x_k)\right\}$$

és

$$g(s; \theta) = \exp\{\alpha(\theta)s + n\beta(\theta)\},$$

akkor

$$l(x_1, x_2, \dots, x_n; \theta) = h(x_1, x_2, \dots, x_n)g(s; \theta).$$

Fischer-féle információmennyiség

Értelmezés

$A \theta \in \mathbb{R}$ -ra vonatkozó **Fisher féle információ mennyiség** az

$$I_n(\theta) = \mathbb{E} \left[\left(\frac{\partial \ln l(X_1, X_2, \dots, X_n; \theta)}{\partial \theta} \right)^2 \right],$$

várható érték, ha a likelihood függvény deriválható és a várható érték létezik.





Tétel

Ha X értelmezési tart nem függ θ -tól és a likelihood függvény kétszer deriválható θ -ra, akkor

$$I_n(\theta) = -\mathbb{E} \left(\frac{\partial^2 \ln l(X_1, X_2, \dots, X_n; \theta)}{\partial \theta^2} \right).$$

Bizonyítás Tudjuk, hogy

$$\int_{\mathbb{R}^n} l(x_1, x_2, \dots, x_n; \theta) dx_1 dx_2 \dots dx_n = 1.$$

θ szerint deriválva és felhasználva, hogy

$$\frac{\partial l(x_1, x_2, \dots, x_n; \theta)}{\partial \theta} = l(x_1, x_2, \dots, x_n) \frac{\partial \ln l(x_1, x_2, \dots, x_n; \theta)}{\partial \theta},$$

$$\int_{\mathbb{R}^n} \frac{\partial \ln l(x_1, x_2, \dots, x_n; \theta)}{\partial \theta} l(x_1, x_2, \dots, x_n; \theta) dx_1 dx_2 \dots dx_n = 0$$

θ szerint ismét deriválva,

$$\begin{aligned} & \int_{\mathbb{R}^n} \frac{\partial^2 \ln l(x_1, x_2, \dots, x_n; \theta)}{\partial \theta^2} l(x_1, x_2, \dots, x_n; \theta) dx_1 dx_2 \dots dx_n + \\ & + \int_{\mathbb{R}^n} \frac{\partial \ln l(x_1, x_2, \dots, x_n; \theta)}{\partial \theta} \frac{\partial l(x_1, x_2, \dots, x_n; \theta)}{\partial \theta} dx_1 dx_2 \dots dx_n = 0. \end{aligned}$$



Bizonyítás

vagy

$$\int_{\mathbb{R}^n} \frac{\partial^2 \ln l(x_1, x_2, \dots, x_n; \theta)}{\partial \theta^2} l(x_1, x_2, \dots, x_n; \theta) dx_1 dx_2 \dots dx_n +$$
$$+ \int_{\mathbb{R}^n} \left(\frac{\partial \ln l(x_1, x_2, \dots, x_n; \theta)}{\partial \theta} \right)^2 l(x_1, x_2, \dots, x_n; \theta) dx_1 dx_2 \dots dx_n = 0.$$

Igy

$$\mathbb{E} \left(\frac{\partial^2 \ln l(X_1, X_2, \dots, X_n; \theta)}{\partial \theta^2} \right) + \mathbb{E} \left[\left(\frac{\partial \ln l(X_1, X_2, \dots, X_n; \theta)}{\partial \theta} \right)^2 \right] = 0$$

Diszkrét esetre a bizonyítás hasonló. ■





Tétel

Ha az X értelmezési tartománya nem függ θ -tól, akkor
 $I_n(\theta) = nI_1(\theta)$.

Bizonyítás Ismétléssel húzunk, tehát

$$\frac{\partial^2 \ln l(x_1, x_2, \dots, x_n; \theta)}{\partial \theta^2} = \sum_{k=1}^n \frac{\partial^2 \ln f(x_k; \theta)}{\partial \theta^2}.$$

A előbbi tétel szerint

$$I_n(\theta) = - \sum_{k=1}^n \mathbb{E} \left(\frac{\partial^2 \ln f(X_k; \theta)}{\partial \theta^2} \right) = \sum_{k=1}^n I_1(\theta) = nI_1(\theta),$$

mivel

$$I_1(\theta) = -\mathbb{E} \left(\frac{\partial^2 \ln f(X; \theta)}{\partial \theta^2} \right).$$





Példa

Legyen X normális eloszlású valószínűségi változó, $N(m, \sigma)$, ahol $m \in \mathbb{R}$ ismeretlen, $\sigma > 0$ ismert.

$$f(x; m) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-m)^2}{2\sigma^2}}, \quad x \in \mathbb{R},$$

$\Rightarrow$



$$I_1(m) = E \left[\left(\frac{\partial \ln f(X; m)}{\partial m} \right)^2 \right] = \mathbb{E} \left(\frac{(X - m)^2}{\sigma^4} \right) = \frac{1}{\sigma^2}.$$

Így

$$I_n(m) = \frac{n}{\sigma^2}.$$



Tétel

Legyen $(X_1, \dots, X_n)$ egy $\theta \in \mathbb{R}$ paramétertől függő eloszlásból származó megfigyelés. Legyen $T = T(X_1, X_2, \dots, X_n)$ egy elégséges statisztika. Jelölje $I_T(\theta)$ a T statisztika információmennységét. Ekkor az $I_T(\theta)$ θ -ra vonatkozó információmennysége kisebb $I_n(\theta)$ -nál

$$I_T(\theta) \leq I_n(\theta).$$



A becslés jellemzői

Legyen $X_1, \dots, X_n$ egy $\theta \in \mathbb{R}$ paramétertől függő eloszlásból származó megfigyelés.

Értelmezés

Egy

$$\hat{\Theta} = \hat{\theta}(X_1, X_2, \dots, X_n),$$

*statisztikát **becslés függvénynek** nevezzük a θ paraméterre, értéke $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$ a θ becslése.*





A következő értelmezések a becslés "jóságát" jellemz

Értelmezés

A $\hat{\Theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ a θ

torzítatlan becslése, ha $\mathbb{E}(\hat{\Theta}) = \theta$.

konzisztens becslése, ha $\hat{\Theta} \xrightarrow{P} \theta$, vagyis

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\hat{\Theta} - \theta| < \varepsilon) = 1, \forall \varepsilon > 0$$

.

abszolút korrekt becslése, ha

i) $\mathbb{E}(\hat{\Theta}) = \theta$,

ii) $\lim_{n \rightarrow \infty} \mathbb{D}^2(\hat{\Theta}) = 0$,



Tétel

Egy abszolút korrekt becslésfüggvény konzisztens.

Bizonyítás Csebisev egyenlőtlenségből

$$1 \geq \mathbb{P}(|\hat{\Theta} - \theta| < \varepsilon) \geq 1 - \frac{\mathbb{D}^2(\hat{\Theta})}{\varepsilon^2}, \forall \varepsilon > 0$$

akkor

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\hat{\Theta} - \theta| < \varepsilon) = 1, \forall \varepsilon > 0$$





A következő értelmezések a becslés "jóságát" jellemz

Értelmezés

A $\hat{\Theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ a θ

torzítatlan becslése, ha $\mathbb{E}(\hat{\Theta}) = \theta$.

konzisztens becslése, ha $\hat{\Theta} \xrightarrow{P} \theta$, vagyis

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\hat{\Theta} - \theta| < \varepsilon) = 1, \forall \varepsilon > 0$$

.

abszolút korrekt becslése, ha

i) $\mathbb{E}(\hat{\Theta}) = \theta$,

ii) $\lim_{n \rightarrow \infty} \mathbb{D}^2(\hat{\Theta}) = 0$,



Tétel

Egy abszolút korrekt becslésfüggvény konzisztens.

Bizonyítás Csebisev egyenlőtlenségből

$$1 \geq \mathbb{P}(|\hat{\Theta} - \theta| < \varepsilon) \geq 1 - \frac{\mathbb{D}^2(\hat{\Theta})}{\varepsilon^2}, \forall \varepsilon > 0$$

akkor

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\hat{\Theta} - \theta| < \varepsilon) = 1, \forall \varepsilon > 0$$





Értelmezés

A $\hat{\Theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ a θ paraméterre **korrekt becslés**,
ha

$$i) \lim_{n \rightarrow \infty} \mathbb{E}(\hat{\Theta}) = \theta,$$

$$ii) \lim_{n \rightarrow \infty} \mathbb{D}^2(\hat{\Theta}) = 0.$$





Feladat

Adjon példát olyan becslésre, amely korrekt de nem agszolút korrekt.





Tétel

Egy korrekt becslés konzisztens.



Valószínűség és statisztika



Bizonyítás Legyen $\hat{\Theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ korrekciós becslés θ -ra (i) és (ii)ből bármely $\varepsilon > 0$ és $\delta > 0$ -ra létezik $N = N(\varepsilon, \delta)$

$$|E(\hat{\Theta}) - \theta| < \frac{\varepsilon}{2}, \quad D^2(\hat{\Theta}) < \frac{\varepsilon^2 \delta}{4},$$

$n > N$ -re. Felírhatjuk, hogy

$$|\hat{\Theta} - \theta| \leq |\hat{\Theta} - E(\hat{\Theta})| + |E(\hat{\Theta}) - \theta| < |\hat{\Theta} - E(\hat{\Theta})| + \frac{\varepsilon}{2},$$

$n > N$ -ra, ahonnan $|\hat{\Theta} - E(\hat{\Theta})| < \frac{\varepsilon}{2}$, innen $|\hat{\Theta} - \theta| < \varepsilon$,
 $n > N$ -ra. Tehát

$$\left(|\hat{\Theta} - E(\hat{\Theta})| < \frac{\varepsilon}{2}\right) \subset \left(|\hat{\Theta} - \theta| < \varepsilon\right), \quad n > N,$$

Innen

$$P\left(|\hat{\Theta} - E(\hat{\Theta})| < \frac{\varepsilon}{2}\right) \leq P(|\hat{\Theta} - \theta| < \varepsilon), \quad n > N.$$



Másrészt a Csebisev egyenlőtlenségből,

$$P\left(|\hat{\Theta} - E(\hat{\Theta})| < \frac{\varepsilon}{2}\right) \geq 1 - \frac{4D^2(\hat{\Theta})}{\varepsilon^2}.$$

Mivel $D^2(\hat{\Theta}) < \frac{\varepsilon^2 \delta}{4}$, $n > N$ -ra,

$$P\left(|\hat{\Theta} - E(\hat{\Theta})| < \frac{\varepsilon}{2}\right) \geq 1 - \delta, \quad n > N.$$

Innen

$$P\left(|\hat{\Theta} - \theta| < \varepsilon\right) \geq P\left(|\hat{\Theta} - E(\hat{\Theta})| < \frac{\varepsilon}{2}\right) \geq 1 - \delta, \quad n > N.$$

ahonnan $\hat{\Theta} \xrightarrow{p} \theta$. ■





Tétel

Ha az X jellemzőre létezik $\nu_{2k} = \mathbb{E}(X^{2k})$, és egy n elemű visszatevéses mintavételt végzünk, akkor

$$\bar{\nu}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

abszolút korrekt becslésfüggvénye ν_k -nek.

Bizonyítás Tudjuk, hogy $\mathbb{E}(\bar{\nu}_k) = \nu_k$ és

$$\lim_{n \rightarrow \infty} \mathbb{D}^2(\bar{\nu}_k) = \lim_{n \rightarrow \infty} \frac{\nu_{2k} - \nu_k^2}{n} = 0.$$

Igy az értelmezés feltételei teljesülnek. ■



Tétel

Ha az X jellemzőre létezik $\nu_{2k} = \mathbb{E}(X^{2k})$, akkor $\bar{\mu}_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$ korrekt becslés a k rendű centrált momentumra, $\mu_k = \mathbb{E}((X - E(X))^k)$ -ra

Bizonyítás Egyrészt

$$\lim_{n \rightarrow \infty} \mathbb{E}(\bar{\mu}_k) = \lim_{n \rightarrow \infty} \left(\mu_k + O\left(\frac{1}{n}\right) \right) = \mu_k.$$

Másrészt

$$\lim_{n \rightarrow \infty} \mathbb{D}^2(\bar{\mu}_k) = \lim_{n \rightarrow \infty} \left[\frac{\mu_{2k} - 2k\mu_{k-1}\mu_{k+1} - \mu_k^2 + k^2\mu_k\mu_{k-1}^2}{n} + O\left(\frac{1}{n^2}\right) \right]$$





Feladat

Igazolja, hogy $\bar{\mu}_2$ korrekt becslés a $\mathbb{D}^2(X) (= \mu_2)$ -re.





Rao-Cramer egyenlőtlenség

a becslések szórásnégyzetei nem lehetnek kisebbek egy a statisztikai minta információtartalmától függő pozitív határszámnál.

Tétel

Az X jellemző valószínűségfüggvénye, $f(x; \theta)$, $\theta \in]a, b[$, θ szerinti parciálisan deriválható és $\hat{\Theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ a θ torzítatlan becslése, akkor

$$\mathbb{D}^2(\hat{\Theta}) \geq \frac{1}{I_n(\theta)} \cdot \mathbb{I}$$





Bizonyítás A $\hat{\Theta}$ torzítatlan becslés, ezért $\mathbb{E}(\hat{\Theta}) = \theta$

vagyis

$$\int_{\mathbb{R}^n} \hat{\theta}(x_1, x_2, \dots, x_n) g(x_1, x_2, \dots, x_n; \theta) dx_1 dx_2 \dots dx_n = \theta,$$

ahol $g(x_1, x_2, \dots, x_n; \theta) = \prod_{k=1}^n f(x_k; \theta)$ hihetőségi függvény.

θ szerint deriválva

$$\int_{\mathbb{R}^n} \hat{\theta}(x_1, x_2, \dots, x_n) \sum_{k=1}^n f(x_1; \theta) \dots \frac{\partial f(x_k; \theta)}{\partial \theta} \dots f(x_n; \theta) dx_1 dx_2 \dots dx_n = 0,$$

vagy

$$\int_{\mathbb{R}^n} \hat{\theta}(x_1, x_2, \dots, x_n) \left(\sum_{k=1}^n \frac{\partial \ln f(x_k; \theta)}{\partial \theta} \right) \left(\prod_{i=1}^n f(x_i; \theta) \right) dx_1 dx_2 \dots dx_n = 0.$$

Mivel

$$\int_{\mathbb{R}} \frac{\partial \ln f(x; \theta)}{\partial \theta} f(x; \theta) dx = 0,$$





Bizonyítás A $\hat{\Theta}$ torzítatlan becslés, ezért $\mathbb{E}(\hat{\Theta}) = \theta$ vagyis

$$\int_{\mathbb{R}^n} \hat{\theta}(x_1, x_2, \dots, x_n) g(x_1, x_2, \dots, x_n; \theta) dx_1 dx_2 \dots dx_n = \theta,$$

ahol $g(x_1, x_2, \dots, x_n; \theta) = \prod_{k=1}^n f(x_k; \theta)$ hihetőségi függvény.

θ szerint deriválva

$$\int_{\mathbb{R}^n} \hat{\theta}(x_1, x_2, \dots, x_n) \sum_{k=1}^n f(x_1; \theta) \dots \frac{\partial f(x_k; \theta)}{\partial \theta} \dots f(x_n; \theta) dx_1 dx_2 \dots dx_n = 0,$$

vagy

$$\int_{\mathbb{R}^n} \hat{\theta}(x_1, x_2, \dots, x_n) \left(\sum_{k=1}^n \frac{\partial \ln f(x_k; \theta)}{\partial \theta} \right) \left(\prod_{i=1}^n f(x_i; \theta) \right) dx_1 dx_2 \dots dx_n = 0.$$

Mivel

$$\int_{\mathbb{R}} \frac{\partial \ln f(x; \theta)}{\partial \theta} f(x; \theta) dx = 0,$$



írhatjuk, hogy

$$\theta \sum_{k=1}^n \int \cdots \int_{\mathbb{R}^n} \frac{\partial \ln f(x_k; \theta)}{\partial \theta} \left(\prod_{i=1}^n f(x_i; \theta) \right) dx_1 dx_2 \dots dx_n = 0,$$

Kivonva az előzőből

$$\int_{\mathbb{R}^n} \left(\hat{\theta}(x_1, \dots, x_n) - \theta \right) \left(\sum_{k=1}^n \frac{\partial \ln f(x_k; \theta)}{\partial \theta} \right) f(x_1, \dots, x_n; \theta) dx_1 \dots dx_n$$

vagyis

$$\mathbb{E} \left[\left(\hat{\theta}(X_1, X_2, \dots, X_n) - \theta \right) \left(\sum_{k=1}^n \frac{\partial \ln f(X_k; \theta)}{\partial \theta} \right) \right] = 0.$$

A Cauchy-Schwarz egyenlőtlenséget alkalmazva:

$$1 = \left[\mathbb{E} \left[\left(\hat{\theta}(X_1, X_2, \dots, X_n) - \theta \right) \left(\sum_{k=1}^n \frac{\partial \ln f(X_k; \theta)}{\partial \theta} \right) \right] \right]^2 \leq$$



$$\leq \mathbb{E} \left[\left(\hat{\theta}(X_1, X_2, \dots, X_n) - \theta \right)^2 \right] \mathbb{E} \left[\left(\sum_{k=1}^n \frac{\partial \ln f(X_k; \theta)}{\partial \theta} \right)^2 \right]$$

$$= \mathbb{D}^2(\hat{\Theta}) \mathbb{D}^2 \left(\sum_{k=1}^n \frac{\partial \ln f(X_k; \theta)}{\partial \theta} \right) = \mathbb{D}^2(\hat{\Theta}) \cdot n \mathbb{D}^2 \left(\frac{\partial \ln f(X; \theta)}{\partial \theta} \right),$$

vagyis

$$\mathbb{D}^2(\hat{\Theta}) \geq \frac{1}{n \mathbb{D}^2 \left(\frac{\partial \ln f(X; \theta)}{\partial \theta} \right)}.$$

De

$$I_n(\theta) = n I_1(\theta) = n \mathbb{E} \left[\left(\frac{\partial \ln f(X; \theta)}{\partial \theta} \right)^2 \right] = n \mathbb{D}^2 \left(\frac{\partial \ln f(X; \theta)}{\partial \theta} \right),$$

amit az előbbibe behelyettesítve a Rao-Cramér egyenlőtlenséget kapjuk. ■



Értelmezés

Egy torzítatlan $\hat{\Theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ becslés hatékonyságát az

$$e(\hat{\Theta}) = \frac{I_n^{-1}(\theta)}{\mathbb{D}^2(\hat{\Theta})}.$$

hatásfok adja.

A Rao-Cramér egyenlőtlenségből

$$0 \leq e(\hat{\Theta}) \leq 1.$$

Értelmezés

A θ -ra vonatkozó abszolút korrekt becslés, **hatékony**, ha

$$e(\hat{\Theta}) = 1$$





Értelmezés

$A \hat{\Theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ torzítatlan becslés optimális, ha szórása minimális.

Egy hatásos becslés optimális, fordítva nem feltétlenül igaz az állítás.





Módszerek paraméterbecslésre

Az eloszlásfüggvényparamétereinek becslése momentum módszerrel

X , $f(x; \theta)$ a sűrűségfüggvény, $\theta = (\theta_1, \theta_2, \dots, \theta_p) \in A \subset \mathbb{R}^p$ ismeretlen és n elemű mintavétel.

Értelmezés

θ -ra egy momentumból kapott becslés a $\bar{\Theta} = (\bar{\Theta}_1, \bar{\Theta}_2, \dots, \bar{\Theta}_p)$ megoldása a

$$\nu_k = \bar{\nu}_k, \quad k = \overline{1, p},$$

rendszernek, ahol $\nu_k = \mathbb{E}(X^k)$, 

$$\bar{\nu}_k = \frac{1}{n} \sum_{i=1}^n x_i^k.$$





Példa

Ha X gamma eloszlású, $a, b > 0$ ismeretlen,

$$f(x; a, b) = \frac{1}{\Gamma(a)b^a} x^{a-1} e^{-\frac{x}{b}}, \quad x > 0.$$

Tudjuk, hogy

$$\nu_1 = \mathbb{E}(X) = ab, \quad \nu_2 = \mathbb{E}(X^2) = ab(b+1).$$

A rendszer:

$$ab = \bar{\nu}_1 = \bar{X}$$

$$ab^2(a+1) = \bar{\nu}_2 = \bar{X}^2 + \bar{\mu}_2,$$

$\Rightarrow$

$$\bar{a} = \frac{\bar{X}^2}{\bar{\mu}_2}, \quad \bar{b} = \frac{\bar{\mu}_2}{\bar{X}}.$$



Az eloszlásfüggvényparamétereinek becslése maximum-likelihood módszerrel

$X, f(x; \theta), \theta \in A \subset \mathbb{R}$ ismeretlen és n elemű mintavétel.

Értelmezés

θ -ra a $\hat{\Theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ statisztika maximum-likelihoode becslés, ha a

$$l(x_1, x_2, \dots, x_n; \theta) = \prod_{k=1}^n f(x_k; \theta),$$

likelihoode függvénynek θ -ban maximuma van, a

$$\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$$

a θ paraméter maximum-likelihoode becslése.



Ha a likelihood függvény kétszer differenciálható θ szerint, akkor a maximum-likelihood becslést a

$$\frac{\partial l(X_1, X_2, \dots, X_n; \theta)}{\partial \theta} = 0,$$

$$\left. \frac{\partial^2 l(X_1, X_2, \dots, X_n; \theta)}{\partial \theta^2} \right|_{\theta = \hat{\theta}} < 0.$$

megoldásából kapjuk, amely ekvivalens a

$$\frac{\partial \ln l(X_1, X_2, \dots, X_n; \theta)}{\partial \theta} = \sum_{k=1}^n \frac{\partial \ln f(X_k; \theta)}{\partial \theta} = 0,$$

$$\left. \frac{\partial^2 \ln l(X_1, X_2, \dots, X_n; \theta)}{\partial \theta^2} \right|_{\theta = \hat{\theta}} < 0.$$

rendszerrel.



Tétel

Ha $S = S(X_1, X_2, \dots, X_n)$ a θ -ra elégséges statisztika, és $\hat{\Theta}$ a θ -ra maximum-likelihood becslés, akkor $\hat{\Theta}$ az S függvénye.

Bizonyítás S elégséges, tehát

$$l(x_1, x_2, \dots, x_n; \theta) = \varphi(x_1, x_2, \dots, x_n)h(s, \theta),$$

vagyis g maximuma θ szerint a h nak a θ szerinti maximumával esik egybe. Így $\hat{\Theta}$ az S függvénye. ■



Feladat

Adjon maximum-likelihood becslést a normáeloszlás paraméterire egy n elemű mintavételből.





Intervallumbecslés

egy olyan véletlen intervallumot határozunk meg, amely adott valószínűséggel lefedi a θ paraméter értékét.
 $\alpha \in]0, 1[$ szignifikanciaszint, $1 - \alpha$ konfidenciaszint.

Értelmezés

A θ paraméter konfidenciaintervalluma a

$$(\bar{\Theta}_1, \bar{\Theta}_2) = (\bar{\theta}_1(X_1, X_2, \dots, X_n), \bar{\theta}_2(X_1, X_2, \dots, X_n)),$$

ahol $\bar{\Theta}_1$ és $\bar{\Theta}_2$ olyan statisztikák, amelyekre

$$\mathbb{P}(\bar{\Theta}_1 < \theta < \bar{\Theta}_2) = 1 - \alpha,$$

a

$$(\bar{\theta}_1, \bar{\theta}_2) = ((\bar{\theta}_1(x_1, x_2, \dots, x_n), \bar{\theta}_2(x_1, x_2, \dots, x_n)))$$

numerikus intervallum a konfidenciaintervallum értéke.





3

(3 of 17)



$T = T(X_1, X_2, \dots, X_n)$ statisztika, θ ismeretlen.
Meghatározzuk az (t_1, t_2) intervallumot, amelyre

$$\mathbb{P}(T \in (t_1, t_2)) = 1 - \alpha,$$

vagy

$$\mathbb{P}(\bar{\Theta}_1 < \theta < \bar{\Theta}_2) = 1 - \alpha.$$

- A becslés annál jobb minél kisebb α .
- A $\mathbb{P}(T \in (t_1, t_2)) = 1 - \alpha$ -ból az (t_1, t_2) intervallum meghatározása nem egyértelmű.



4

(4 of 17)



a) Konfidenciaintervallum meghatározása $N(m, \sigma)$, ahol $m \in \mathbb{R}$ ismeretlen, $\sigma > 0$ ismert.

$\alpha \in (0, 1)$

$$Z = \frac{\bar{X} - m}{\frac{\sigma}{\sqrt{n}}},$$

amely $N(0, 1)$ eloszlású.

meghatározzuk a $]z_1, z_2[$ intervallumot:

$$\mathbb{P}(Z \in (z_1, z_2)) = \Phi(z_2) - \Phi(z_1) = 1 - \alpha,$$

ahol

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_0^x e^{-\frac{t^2}{2}} dt,$$

a Laplace függvény.



5

(5 of 17)



$$z_1 < \frac{\bar{X} - m}{\frac{\sigma}{\sqrt{n}}} < z_2$$

ekvivalens a

$$\bar{m}_1 = \bar{X} + z_2 \frac{\sigma}{\sqrt{n}} < m < \bar{X} + z_1 \frac{\sigma}{\sqrt{n}} = \bar{m}_2$$

tehát

$$\mathbb{P}(\bar{m}_1 < m < \bar{m}_2) = 1 - \alpha,$$





A $]z_1, z_2[$ nem egyértelmű.

Legyen $z_1 = -z_2$, $z_2 = z_{1-\frac{\alpha}{2}}$ -t,

$$\Phi(z_{1-\frac{\alpha}{2}}) - \Phi(-z_{1-\frac{\alpha}{2}}) = 1 - \alpha$$

$$\Leftrightarrow \Phi(z_{1-\frac{\alpha}{2}}) = \frac{1 - \alpha}{2}.$$

A konfidenciaintervallum szélsőértékei

$$\bar{m}_1 = \bar{m}_1(X_1, X_2, \dots, X_n) = \bar{X} - z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}},$$

$$\bar{m}_2 = \bar{m}_2(X_1, X_2, \dots, X_n) = \bar{X} + z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}.$$





7 (7 of 17)



b) Konfidenciaintervallum meghatározása $N(m, \sigma)$, ahol $m \in \mathbb{R}$ és $\sigma > 0$ ismeretlen.

Legyen a

$$T = \frac{\bar{X} - m}{\frac{\bar{\sigma}}{\sqrt{n}}} = \frac{\bar{X} - m}{\sqrt{\frac{\bar{\mu}_2}{n-1}}},$$

statisztika $n - 1$ szabadságfokú Student eloszlású.

$$\mathbb{P}(T \in]t_1, t_2[) = F_{n-1}(t_2) - F_{n-1}(t_1) = 1 - \alpha,$$

ahol

$$F_m(x) = \frac{\Gamma(\frac{m+1}{2})}{\sqrt{m\pi}\Gamma(\frac{m}{2})} \int_{-\infty}^x \left(1 + \frac{t^2}{m}\right)^{-\frac{m+1}{2}} dt, \quad x \in \mathbb{R},$$



Legyen $t_2 = t_{n-1, 1-\frac{\alpha}{2}}$, $t_1 = -t_2$, ekkor

$$\mathbb{F}_{n-1}(t_{n-1, 1-\frac{\alpha}{2}}) = 1 - \frac{\alpha}{2},$$

igy $P(\bar{m}_1 < m < \bar{m}_2) = 1 - \alpha$, tehát az m -re vonatkozó konfidenciaintervallum szélsőértékei

$$\bar{m}_1 = \bar{X} - t_{n-1, 1-\frac{\alpha}{2}} \frac{\bar{\sigma}}{\sqrt{n}},$$

$$\bar{m}_2 = \bar{X} + t_{n-1, 1-\frac{\alpha}{2}} \frac{\bar{\sigma}}{\sqrt{n}}.$$





9

(9 of 17)



c) Konfidenciaintervallum meghatározása $N(m, \sigma)$ szórásnégyzetének meghatározására
Tekintsük a

$$\chi^2 = \frac{(n-1)\bar{\sigma}^2}{\sigma^2} = \frac{1}{\sigma^2} \sum_{k=1}^n (X_k - \bar{X})^2,$$

amely χ^2 eloszlású $n-1$ szabadságfokkal.
Meghatározzuk a $]\chi_1^2, \chi_2^2[$:

$$\mathbb{P}(\chi^2 \in (\chi_1^2, \chi_2^2)) = F_{n-1}(\chi_2^2) - F_{n-1}(\chi_1^2) = 1 - \alpha,$$

ahol

$$F_m(x) = \frac{1}{2^{\frac{m}{2}} \Gamma(\frac{m}{2})} \int_0^x t^{\frac{m}{2}-1} e^{-\frac{t}{2}} dt, \quad x > 0,$$

a χ^2 eloszlás eloszlásfüggvénye m szabadságfokkal.



Legyen $\chi_1^2 = \chi_{n-1, \frac{\alpha}{2}}^2$ és $\chi_2^2 = \chi_{n-1, 1-\frac{\alpha}{2}}^2$, vagyis

$$\mathbb{F}_{n-1}(\chi_{n-1, \frac{\alpha}{2}}^2) = \frac{\alpha}{2}, \quad \mathbb{F}_{n-1}(\chi_{n-1, 1-\frac{\alpha}{2}}^2) = 1 - \frac{\alpha}{2},$$

akkor $\mathbb{P}(\bar{\sigma}^2 < \sigma^2 < \bar{\sigma}^2) = 1 - \alpha$, ahol

$$\bar{\sigma}_1^2 = \bar{\sigma}_1^2(X_1, X_2, \dots, X_n) = \frac{(n-1)\bar{\sigma}^2}{\chi_{n-1, 1-\frac{\alpha}{2}}^2},$$

$$\bar{\sigma}_2^2 = \bar{\sigma}_2^2(X_1, X_2, \dots, X_n) = \frac{(n-1)\bar{\sigma}^2}{\chi_{n-1, \frac{\alpha}{2}}^2}.$$





d) Konfidenciaintervallum meghatározása nagy mintánál esetén.

X sűrűségfüggvénye $f(x; \theta)$, $\theta \in A \subset \mathbb{R}$ ismeretlen.

Tétel

Ha $Y_1, Y_2, \dots, Y_n$

$$Y_k = \frac{\partial \ln f(X_k; \theta)}{\partial \theta}, \quad \exists \mathbb{D}^2(Y_k) = d^2 > 0$$

akkor a

$$Z = \frac{1}{d\sqrt{n}} \sum_{k=1}^n Y_k = \frac{1}{d\sqrt{n}} \sum_{k=1}^n \frac{\partial \ln f(X_k; \theta)}{\partial \theta},$$

statisztika $n \rightarrow \infty$ esetén, $N(0, 1)$ eloszlású.



Bizonyítás X_k , $k = \overline{1, n}$, valószínűségi változók függetlenek, azonos eloszlásúak tehát Y_k , $k = \overline{1, n}$, is független és azonos eloszlású. A központi határeloszlás tétele szerint

$$Y_{(n)} \stackrel{\mathbb{F}}{=} \frac{1}{d\sqrt{n}} \sum_{k=1}^n (Y_k - \mathbb{E}(Y_k))$$

eloszlásban $N(0, 1)$ -hoz tart.

Másrészt

$$\mathbb{E}(Y_k) = \mathbb{E} \left(\frac{\partial \ln f(X_k; \theta)}{\partial \theta} \right) = 0,$$

miatt $Y_{(n)} = Z$. ■



Adott $1 - \alpha$ konfidenciaszintremeghatározzuk a $]-z_{1-\frac{\alpha}{2}}, z_{1-\frac{\alpha}{2}})$ intervallumot:

$$\mathbb{P}(Z \in (-z_{1-\frac{\alpha}{2}}, z_{1-\frac{\alpha}{2}})) = 2\Phi(z_{1-\frac{\alpha}{2}}) = 1 - \alpha.$$

$$\text{I} \quad \Phi(z_{1-\frac{\alpha}{2}}) = \frac{1 - \alpha}{2}.$$

A

$$|Z| < z_{1-\frac{\alpha}{2}}$$

egyenlőtlenségből a konfidenciaintervallum

$$\bar{\theta}_1(X_1, X_2, \dots, X_n) < \theta < \bar{\theta}_2(X_1, X_2, \dots, X_n),$$



Feladat

Legyen X az 1 és 0 értékű valószínűségi változó, melynek sűrűségfüggvénye

$$f(x; p) = p^x(1 - p)^{1-x}, \quad x = 0, 1,$$

ahol $p \in]0, 1[$ ismeretlen. Határozza meg a konfidenciaintervallumot a p paraméterre.



Megoldás

Mivel

$$\ln f(x; p) = x \ln p + (1 - x) \ln(1 - p)$$

$$\Rightarrow \frac{\partial \ln f(x; p)}{\partial p} = \frac{x}{p} - \frac{1 - x}{1 - p} = \frac{x - p}{p(1 - p)},$$

így a

$$Z = \frac{1}{d\sqrt{n}} \sum_{k=1}^n \frac{X_k - p}{p(1 - p)} = \frac{\sqrt{n}}{p(1 - p)d} (\bar{X} - p).$$

statisztikát használjuk. $\mathbb{D}^2(X) = p(1 - p)$

$$\Rightarrow d^2 = \mathbb{D}^2 \left(\frac{\partial \ln f(X_k; p)}{\partial p} \right) = \mathbb{D}^2 \left(\frac{X_k - p}{p(1 - p)} \right) = \frac{1}{p^2(1 - p)^2} D^2($$

$$= \frac{1}{p^2(1 - p)^2} p(1 - p) = \frac{1}{p(1 - p)}.$$



$$Z = \frac{\sqrt{n}}{\sqrt{p(1-p)}}(\bar{X} - p)$$

$N(0, 1)$ eloszlású, ha $n \rightarrow \infty$.

$$\mathbb{P}(|Z| < z) = 1 - \alpha.$$

A $|Z| < z$ ekvivalens a

$$\frac{n(\bar{X} - p)^2}{p(1-p)} < z^2,$$

vagy

$$(n + z^2)p^2 - (2n\bar{X} + z^2)p + n\bar{X}^2 < 0.$$



De

$$\Delta = z^2 \left[z^2 + 4n\bar{X}^2(n-1) \right] > 0,$$

A p -ben másodfokú egyenlőtlenség megoldása $]\bar{p}_1, \bar{p}_2[$ alakú, a p paraméterre konfidenciaintervallum.